

工學碩士學位請求論文

조명 환경에 적응적인 얼굴 인식 시스템

**Adaptive Face Recognition System For Varying  
Illumination Environment**

2004年 2月

仁荷大學校 大學院

電子計算工學科

李 在 薰

工學碩士學位請求論文

조명 환경에 적응적인 얼굴 인식 시스템

**Adaptive Face Recognition System For Varying  
Illumination Environment**

2004 年 2月

指導教授 李 弼 奎

이 論文을 碩士學位 論文으로 提出함

仁荷大學校 大學院

電子計算工學科

李 在 薰

이 論文을 李在薰의 碩士學位 論文으로 認定함

2004 년 2 월 일

主審 \_\_\_\_\_ 印

副審 \_\_\_\_\_ 印

委員 \_\_\_\_\_ 印

## 요 약

최근 정보보안 및 지능형 비전시스템에 대한 관심이 높아짐에 따라 얼굴인식 기술이 중요한 부분으로 부각되었다. 그러나 시시각각 변화하는 환경에서 개인의 얼굴에 대한 인식은 여러 가지 영상에 대한 외부적 요인으로 인해 정확하고 빠른 판단이 어렵다. 특히 열악한 외부환경에서는 조명의 영향에 따라 영상의 특성이 완전히 바뀌므로 그 대응 방법을 찾아내는 것이 매우 중요하다. 따라서 본 논문에서는 진화 알고리즘을 사용한 조명 환경 변수 판단 및 전처리의 방법으로 여러 가지 조명 환경에 대해 상황에 맞게 적절히 대응하고 얼굴인식의 성능을 최대화 할 수 있는 방법을 제안한다.

제안된 방법은 입력된 영상에 대한 조명 환경을 진화신경망을 이용하여 판단하고, 그에 해당하는 적절한 전처리를 진화 알고리즘을 사용하여 찾아낸 후 실제 환경에 대해 적절한 대응이 가능하도록 하였다. 영상의 전처리로는 호모 몰픽 필터와 조명 보정 알고리즘, 히스토그램 평활화 등이 사용되었고, 인식을 위한 데이터의 가보변환이 제안되었다.

얼굴 인식의 판단 실험은 여러 가지 조명 환경의 영향을 받은 영상을 가상으로 만들어 진화신경망을 학습하고 실제 이미지에 대해 조명 환경을 판단하여 영상 필터 처리 후 눈 주위로부터 추출된 가보벡터의 거리 값을 이용하여 개인의 얼굴을 인식하도록 하였다. 실험 결과 여러 가지 복합적인 조명 환경 판단에 대해 제안된 진화 신경망이 94.38%의 성공률로 다른 방법들이 보이는 83.12%의 성공률에 비해 높은 성능을 보였으며, 그에 따라 얼굴의 인식률 역시 97.2%로 비교적 안정적인 성능을 나타내었다.

## ABSTRACT

Recently, the technique of face recognition has been emphasized as an important part as the interest in information security and intelligence vision system have increased. However, in a rapidly changing environment, it is difficult to recognize precisely and rapidly an individual face because of external factors about various images. Especially, it is very important to seek for a solution as the property of an image is influenced and changed by illumination. Accordingly, this paper has proposed methods to be able to increase the capability of face recognition and to deal with various illumination environments through the analysis of illumination environment and a method for pre-processing which use a genetic algorithm.

The methods proposed were to analyze the illumination environment of an image by using evolvable neural network and to permit countersteps proper for real environment after the corresponding pre-processing was sought for by using the genetic algorithm. Homomorphic filter, illumination compensation algorithm and histogram equalization were used as the pre-processing of image and Gabor transform of data was proposed for recognition.

Virtual images, which were affected by various illumination environments, were made for the face recognition experiment, evolvable neural network was studied and the illumination environment for real image was analyzed. And after the pre-processing, the distance of Gabor vector obtained around an individual's eyes was used to recognize his or her face. According to

the experimental results, the evolvable neural network, which had been proposed for the analysis of various and complex illumination environment, showed success probability, 94.38 %, which were higher than 83.12% which other methods showed. As a result, the success rate in face recognition was also 97.2%, which showed relatively stable performance.

## 목 차

요 약 .....	i
ABSTRACT .....	ii
목 차 .....	iv
1. 서론 .....	1
2. 얼굴 인식 기술과 조명의 영향 .....	2
3. 조명 환경 요인과 전처리 .....	4
3.1 조명 환경 모델링 .....	4
3.2 진화신경망을 이용한 조명 환경 판단 .....	6
3.3 조명 환경 변화의 상쇄를 위한 전처리 .....	11
3.4 진화 알고리즘을 이용한 전처리 필터의 조합 .....	15
4. 적응적 얼굴 인식 시스템의 구성 .....	17
4.1 진화신경망의 학습 .....	18
4.2 영상 처리 필터 조합 .....	21
4.3 가보 변환 .....	23
4.4 얼굴 영상의 등록 .....	26
4.5 얼굴 인식 .....	27
5. 실험 결과 .....	28
5.1 조명상태 판단에 대한 실험 .....	29
5.2 인식률에 대한 실험 .....	34
6. 결론 및 향후 연구 방향 .....	38
참고 문헌 .....	39

## 1. 서론

얼굴 정보의 인식과 분석은 인공시각의 중요한 부분을 차지하고 있으며, 오랜 시간에 걸쳐 다양한 연구들이 진행되어 온 분야이다. 특히 유비쿼터스 컴퓨팅 환경[1, 2]에서 개인을 판별하기 위해 매우 중요한 기술 중의 하나이며 인간과 컴퓨터간의 인터페이스(Human - Computer Interface)를 획기적으로 개선시켜 줄 수 있는 기능을 가지고 있다. 이를테면, 간단한 영상입력 장치만으로 각종 휴대용 기기에서 개인의 얼굴, 표정을 인식하여 보다 나은 편리성을 제공하거나, 다수의 사람이 출입하는 곳에서 자동적으로 얼굴을 인식하여 미리 마련된 개인화된 서비스를 제공하는 시스템 등에 사용 가능하다[3, 4].

그러나 이러한 이동형, 또는 외부에 설치된 시스템에서는 시시각각 변화하는 환경을 인지하고[5] 그에 대해 스스로 대처를 할 수 있는 기능이 필요하다[6, 7].

본 논문에서 제안하는 얼굴 인식은 디지털화 된 임의의 영상으로부터 진화신경망을 통해 정확한 조명 환경을 판단하고 진화 알고리즘을 사용하여 조명 환경의 영향을 최소화 할 수 있도록 적절한 전처리 필터를 사용하여 최적의 영상을 획득한 후 가보 벡터를 사용, 개인을 정확히 식별해 낼 수 있도록 한다.

학습 데이터는 최초 미리 정의된 조명에 의한 가상 영상을 조명 환경 판단을 위한 진화신경망의 학습으로 사용하고, 같은 영상을 다시 진화 알고리즘을 사용하여 최적의 필터조합을 추출하게 된다. 이렇게 추출된 필터조합을 테스트로 입력된 영상에 적용하여 전처리 과정을 거친 후 결과 영상에 대해 가보벡터 변환[8]을 사용한다. 변환된 가보벡터는 미리 등록된 벡터들과 비교되어 가장 가까운 거리를 가지는 벡터가 선택되게 된다.

본 논문의 구성은 다음과 같다. 2장에서는 얼굴 인식 기술에 대한 기존 연구를 설명하고 3장에서는 조명 환경에 대한 모델링 및 조명 환경 판단을 위한 진화 신경망과 그에 따른 적절한 전처리 위한 진화 알고리즘을 설명한다. 4장에서는 전체적인 얼굴인식 시스템의 구성을, 5장에서는 조명 환경 판단과 얼굴 인식에 대한 실험을 기술하며, 6장에서는 실험 결과를 바탕으로 결론 및 향후 연구 과제에 대해 기술한다.



## 2. 얼굴 인식 기술과 조명의 영향

얼굴 인식 기술에 대한 기존 연구들을 종합해 보면 다음과 같은 방법들이 존재한다.

1. 고유 얼굴(EigenFace)을 이용한 주성분 분석 방법론
2. 탄력적 그래프 정합법을 이용한 방법론
3. LFA를 이용한 방법론
4. 상관관계(correlation)를 이용한 방법론
5. 신경회로망을 이용한 방법론

고유얼굴(EigenFace)을 이용한 주성분 분석 방법론은 여러 얼굴을 통하여 얼굴의 주성분 즉, 고유얼굴을 추출해 내고 추출된 고유얼굴과 새로 입력된 얼굴의 내적을 통한 가중치 벡터를 추출한다. 추출된 가중치 벡터를 미리 등록된 가중치 벡터와 유사도를 비교함으로써 인식을 수행하게 된다. 이 방법은 인간의 얼굴 인식 기술에서 가장 효율적인 방법으로 입증되어 있다[9]. Sirovich와 Kirby는 처음 사람의 얼굴을 표현하는데 Karhunen-Loeve 변환을 사용하였다[10, 11]. 그들은 이 방법에서 얼굴들을 고유얼굴로 알려진 고유벡터에 선형 가중치 합으로써 나타내었다. Turk와 pentland는 주성분 분석을 사용한 얼굴인식 시스템으로 발전시켰다[12]. 주성분 분석방법은 얼굴인식 뿐만 아니라 성 감별, 인종 감별에도 아주 좋은 분류법으로 사용 될 수 있다[13].

탄력적 그래프 정합법을 이용한 방법론[14, 15]은 전처리 과정을 거친 영상을 토대로 얼굴 검출 및 인식 과정부분을 탄력적인 그래프 정합 알고리즘을 이용하는 것이다. 이 알고리즘은 입력된 영상에 대해 특징점을 추출하고, 추출된 특징점들을 탄력적인 그래프를 이용하여 서로 연결하며, 연결된 특징점들을 가보(Gabor) 함수를 통하여 특징 벡터를 추출해 인식을 수행한다. 그러나 이 방법은 특징점을 추출하는데 시간이 많이 소비되고, 특징점의 정확도에 의해 인식률이 많이 영향을 받는 단점을 가진다[16].

LFA(Local Feature Analysis)를 이용한 방법론[17]은 고유얼굴 방법에서 유도되었는데, 고유얼굴 방법에서의 문제점인 얼굴 표정의 변화, 조명, 자세의 변화 때문에 나타나는 문제점을 해결하고자 제안되었다. LFA는 얼굴의 전역적인 표현에 의존하는 대신에 각 개인의 눈썹, 코, 입 등의 지역적 특성을 이용한다. 그러나 이 방법은 대부분의 특징들이 머리 경계선 부분에서 추출되므로 얼굴의 왜곡에 의해 인식률이 급격히 감소할 수 있다는 단점을 가진다[18].

상관관계(correlation)를 이용한 방법론[19]은 카메라에서 입력된 얼굴 영상을 고유 얼굴 기반으로 얼굴영역을 획득한 후 얻어진 얼굴영역에 대하여 눈을 기준으로 일정한 범위 내에서 모자이크를 형성한다. 실험을 통하여 얻어진 결과에 의하면 인식성능을 좌우하는 것은 눈과 코이며, 얼굴전체와 입은 큰 효과가 없다. 실제로 입 주변 영역은 입의 움직임 및 수염 등의 영향이 크기 때문에 인식에 부적합한 면이 존재한다.

마지막으로, 신경망을 이용한 방법론[20, 21, 22]은 일반적으로 기타의 다른 통계적이나 수식적인 전개 없이 추상적인 데이터에 대해서 학습만으로도 인식이 가능하다. 그러나 신경망은 일정 이상의 크기를 가지는 학습데이터에 대해 수렴속도가 대단히 느려지며, 일반적으로 쓰이는 MLP(Multi layer perceptron)의 경우 학습패턴을 증가시키기 위해 전체 패턴을 다시 학습해야 된다는 단점을 가진다. 또한 지역 최소점에 빠져들어 최적의 해를 찾지 못하는 경우도 발생한다. 따라서 이러한 단점을 보완하기 위해 실험적인 결과를 이용하여 신경망 구조를 정의하거나[23], 진화 알고리즘을 사용하여 신경망을 구성하는 방법이 제안되기도 하였다.

위에서 설명한 얼굴인식 기술들은 모두 외형 기반(Appearance-Based) 모델로, 조명 환경의 변화에 따라 그 성능의 차이가 크게 변할 수 있다. 따라서 이러한 조명의 변화에 따른 영향을 상쇄하기 위한 기법들과[24, 25] 가상 조명을 생성하여[26] 조명의 영향을 미리 판별하고자 하는 연구가 선행되어져 왔으며 그에 따른 인식률이 비교적 안정적으로 나타난 것으로 알려졌다.

### 3. 조명 환경 요인과 전처리

#### 3. 1. 조명 환경 모델링

외부환경에 의한 영상의 변화에 해당하는 조명의 형태는 일반적으로 가산 함수(Additive function)와 승산 함수(Multiplicative function)로 나타내어 질 수 있다. 가산 함수는 실 영상의 화소 값에 독립적으로 변화하고 그 변화되는 부분은 실 영상에 대한 화소 값에 대해서 더해지는 형태로 나타난다. 그 수식은 아래 식 (1)과 같다.

$$A(x, y) = f(x, y) + a(x, y) \quad (1)$$

승산 함수로 생성된 잡영은 화소 값이 실 영상의 화소 값과 같이 변하기 때문에 가산 함수에 의해 생성된 영상에 비해 제거하기가 어렵다. 승산 함수에 의한 잡영 모델에 대한 수식은 아래 식 (2)와 같이 주어진다.

$$M(x, y) = m(x, y) \cdot f(x, y) \quad (2)$$

실제 영상은  $f(x, y)$ , 잡영  $m(x, y)$ 라 하고 잡영을 포함한 영상은  $M(x, y)$ 이다.

대부분의 응용분야에 있어서 입력되는 영상들은 승산 함수에 의한 잡영을 포함하고 있다. 잡영에 대한 random process 변화에 대한 계수를  $\gamma$  라하고  $\gamma$ 는 random process에 대한 표준편차와 평균의 비로써 나타내고 수식은 아래와 같다.

$$\gamma = \frac{\sigma}{\mu} \quad (3)$$

$\mu_n = 1$  인 정상 상태 잡영 처리(Stationary noise process) 경우에는 변화계

수  $\gamma_n = \sigma_n$  이 된다. 이 잡영은 통계적인 방법의 필터(statistical filter)와 주파수 영역처리 필터(frequency domain filter)를 이용하여 제거 가능하다.

두 가지 함수는 아래 식과 같은 형태로 표기가 되며. 여기서  $m$ 이 픽셀의 승산 값이고  $a$ 가 가산 값이다[27].

$$G(x, y) = m(x, y) \cdot f(x, y) + a(x, y) \quad (4)$$

위에서 설명한 두 가지 함수에 의한 잡영들은 영상의  $x, y$  좌표의 값에 따라 변화되는 가중치를 가질 수 있는 함수이다. 가중치 함수로 사용한 함수는  $z = 0$ ,  $z = \sin(x)$ ,  $z = \cos(x)$  들이다.  $z = 0$  함수는 잡영이 고르게 분포되는 것을 의미하며,  $\sin(x)$  와  $\cos(x)$ 는 잡영의 강도가 이미지 공간 좌표인  $x$ 축에 따라 차이남을 의미하며 방향성 있는 잡영에 대한 실험 데이터로 사용할 수 있다. 그림 1은  $\sin(x)$ 와  $\cos(x)$  가중치 함수를 사용한 가상 편향조명 영상을 보여주고 있다.




그림 1. 가중치 함수를 사용한 편향 조명 영상

### 3. 2. 진화신경망을 이용한 조명 환경 판단

인공 신경망은 인간 두뇌의 학습 기능을 컴퓨터에 이식하기 위해 고안되었다. 학습의 기능을 갖는 사람의 두뇌는 다수의 뉴런이 서로 연결된 신경망으로 구성되어 있는데, 인공 신경망은 이러한 생물학적 신경망에서 아이디어를 얻어 사람의 두뇌를 그래프 형태와 수학적 알고리즘으로 모델링한 것이다. 신경망은 생물학적 뉴런을 모델링한 유닛(unit)들과 그 유닛 사이의 가중치 연결(weighted - connection)들로 이루어지며 각 신경망 모델에 따라 다양한 구조와 각기 독특한 학습 규칙을 갖는다[28, 29].

오류 역전파 신경망은 오류 역전파(back-propagation) 학습 알고리즘을 사용한 신경망으로, Rumelhart 등에 의해 구체화되었으며, 감독자 학습 방법(supervised training method)을 사용하는 알고리즘이다[30]. 이 알고리즘은 직감적으로 이해할 수 있으며 또한 프로그래밍 및 하드웨어 제작이 비교적 용이하기 때문에, 주로 패턴인식, 제어 등에서 많이 사용된다.

오류 역전파 신경망은 입력층(input layer), 출력층(output layer), 그리고 한 개 이상의 은닉층(hidden layer)으로 구성된 모델이다. 은닉층은 입력층의 자료에 대해 고도의 추상화를 제공하며, 출력층에 적절한 출력을 제공한다. 입력층에서는 벡터를 입력으로 받아들이며, 상위 은닉층으로 신호를 전달한다. 은닉층은 다시 출력층으로 신호를 전달하여 최종적으로 결정을 하게 된다. 각 층의 노드는 하위층에서 전달되는 입력 신호를 연결강도와 곱해 그 합을 구한다. 구해진 합은 전달함수를 통하여 출력치를 결정한다. 일반적인 전달함수는 식 (5)와 같은 시그모이드 함수를 사용한다.

$$f(x) = \frac{1.0}{1.0 + \exp(-x)} \quad (5)$$

역전파 신경망에서의 학습 과정은 에러 조정 법칙(error-correction rule)으로 다음과 같다. 출력층에서의 나온 결과와 기대결과와의 차이를 노드마다 계산하여 에러를 구한다. 에러를 역으로 전파하여 하위층에서는 이를 근거로 연결강도

를 재조정하여 서서히 최소화할 수 있다. 이러한 과정을 반복하여 충분히 작은 오차가 나온다면 학습을 종료하게 된다. 하나의 노드를  $n$  이라 할 때, 식 (6)은 에러를 계산하는 식이며, 식 (7)은 연결강도를 재조정하는 식이다.

$$E(t) = f'(n(t))(o - n(t)) \quad (t = \text{현재의 epoch}) \quad (6)$$

$$w(t) = w(t-1) + \Delta(t) + \alpha \Delta(t-1) \quad (7)$$

수정되는 연결강도는 이전의 연결강도, 현재 델타 값, 이전의 델타 값을 더해서 나온 값이다. 델타( $\Delta$ )는 출력값과 기대값 간의 에러와 노드의 값에 비례하여 연결강도를 조절하도록 해주는 값으로 식 (8)과 같다.

$$\Delta(t) = \beta \cdot E(t) \cdot n(t) \quad (8)$$

식 (7)에서  $\alpha$ 는 모멘텀(momentum) 상수로 이전의 수정량을 고려하여 수정량을 결정하기 위한 상수이다. 식 (8)은 델타 값을 구하는 식으로, 여기서  $\beta$ 는 학습 상수(learning rate)로 연결강도의 변화율을 결정하는 상수이다.

그러나 오류 역전파 신경망은 중간층과 연결강도의 수가 너무 많으면 응답시간 및 학습시간이 많이 걸리고 초기값에 따라 가중치가 전역 최소값에 도달하지 않으며 계산량이 증가하는 등의 문제가 생긴다. 반면 중간층과 연결강도의 수가 너무 적은 경우에는 입출력 패턴을 기억 못하고 학습이 최적해에 수렴하지 않는다[31, 32].

따라서 이러한 단점을 해결하기 위해 전역 탐색에 탁월한 성능을 보이는 진화 알고리즘을 신경망에 도입하는 방법이 1980년대에 이미 제안되었으며[31, 33] 1990년대에 이르러 그 연구가 활발히 이루어졌다[32, 34, 35].

진화신경망은 신경망의 가중치, 위상 구조, 은닉 노드 수, 학습 알고리즘 등 신경망 학습시 결정해야 하는 인자들을 여러 세대 진화를 통해 찾아서 최적의 신경망을 결정한다[36, 37, 38, 39].

진화 알고리즘을 사용하여 최적의 신경망을 결정하기 위한 방법은 가중치와 연결구조의 최적화가 가장 큰 문제가 된다. 기존의 연구에서는 이들 가중치와 연결구조에 대해 일종의 행렬을 생성하고, 이에 대해 학습 과정에서 진화 전략을 적용시키는 방법을 사용했고[40, 41, 42, 43, 44], 온라인 상에서 실시간으로 진화를 수행하는 연구가 이루어지기도 했다[45].




그림 2. Direct Encoding

기존의 신경망은 Full-link로 각 레이어의 노드들이 모두 연결되어 있는 상태로 표현된다. 그러나 이 연결구조는 진화 알고리즘의 적용을 위해 구조의 변경이 가능하도록 일반화 되어야 하고, 이것은 그림 2와 같이 Direct encoding 방식으로 표현된 방법[36], 즉 연결구조의 행렬 표현을 직접 이진수의 집합으로 정의함으로써 가능해진다.

간단한 예제로, 만약 은닉층이 1개인 신경망에서 입력-은닉-출력층의 노드가 각각 2-2-1 의 신경망의 경우 그림 3과 같은 연결구조를 가진다.




그림 3. 2-2-1 구조의 신경망

Direct Encoding에 의해 위의 신경망은 아래와 같이 표현 될 수 있으며, Encoding 된 이진수를 이용하여 연결구조를 변화시킬 수 있게 된다.




그림 4. 연결구조의 Chromosome 표현

이러한 Direct encoding 방식은 하드웨어 구성에서 각 모듈별 연결에 대해서도 일반화를 시도할 수 있으므로, 보다 넓은 의미에서의 확장구조를 가지게 된다.

연결구조의 표현과 함께, 진화신경망에서의 가중치 역시 다음과 같이 Chromosome 이라고 불리는 이진 스트링으로 표현한다. 이 코딩 방법은 문제의 변수가 이진값 이거나 다른 이산치를 갖는 경우에 특히 자연스러운 표현법이다. 파라미터  $x \in [2^0, 2^l]$ 를 특정 간격  $\pi = [U_{\min}, U_{\max}]$ 로 디코딩 하는 경우 이에 대한 정밀도( $\pi$ )는 식 (9)와 같다.

$$\pi = [U_{\min}, U_{\max}] / [2^0, 2^l] \quad (9)$$

그러나, 실제 적용에 있어서 이 표현방식은 적합하지 않을 수 있으며[46, 47] 신경망의 경우 각 가중치는 실수값으로 표현된다.  $[U_{\min}, U_{\max}]$ 사이의 실수값을 정밀도  $\pi$ 로 코딩하고자 할 때 필요한 스트링의 길이는 식 (10)과 같이 표현되며, 이진 스트링에 대한 원래의 실수 값은 식 (11)로 나타내어진다.



$$l = \lceil \log_2 ( \lfloor U_{\min} , U_{\max} \rfloor / \pi + 1 ) \rceil + 1 \quad (10)$$

$$\text{ival}_{\text{real}} = (\text{ival}_{\text{bin}})_{10} \times \pi + U_{\min} \quad (11)$$

신경망에서는 각 가중치마다 하나씩의 실수 표현이 존재해야 하며[40, 41, 42], 이러한 큰 수의 표현에 대한 연구가 Montana 와 Davis[40]에 의해 이루어졌다.

얼굴인식을 위해 사용되는 영상들은 수많은 외부환경의 영향을 받는다. 그 중에서도 특히 조명의 변화는 인식을 어렵게 만드는 중요한 요소 중의 하나이다.

조명의 판단을 위한 방법에는 여러 가지가 있으며, 가장 간단한 방법으로는 모자이크 영상의 그레이 값의 절대치를 비교하는 것이다. 그러나 이 방법은 정의된 조명 형태가 많을 경우 수많은 경우의 수를 모두 비교해야 하고, 얼굴 형태나 주변요건에 따라 조명의 영향정도가 모자이크 영상에서는 반대로 나타나는 경우도 있기 때문에 실제적인 적용에 어려움이 따른다.

제시된 조명 판단 방법은 진화신경망을 이용하여 인공적으로 이미지에 조명 상태를 만들어 학습한 후 판단하는 방법으로, 기존 역전파 신경망과 절대치를 비교하는 간단한 방법에 비해 보다 나은 성능을 보여주었다.

### 3. 3. 조명 환경 변화의 상쇄를 위한 전처리

이미 알려진 여러 가지 조명의 영향은 그것을 완화하거나 제거하기 위한 필터들이 존재하며, 이러한 필터의 조합을 이용하여 영상의 질을 향상시킬 수 있다. 실험에서 사용된 필터는 세가지로, 다음과 같다.

#### 호모 몰픽 필터(Homomorphic filter)

조명-반사율 모델은 주파수 영역에서의 처리를 통해 영상화질을 개선하기 위한 대비 증가와 동시성 밝기 범위 압축의 기본 원리로 사용된다. 영상  $f(x,y)$ 는 아래 식에 의해 조명과 반사율로 표현할 수 있다.

$$f(x,y) = i(x,y)r(x,y) \quad (12)$$

식 (12)는 조명과 반사율의 주파수 성분을 따로따로 작용할 목적으로는 바로 사용할 수 없다. 왜냐하면 두 함수의 곱의 푸리에 변환(Fourier Transform)은 분리 될 수 없기 때문이다. 따라서 식 (12)의 양변에  $\ln$  을 취하게 되면 두 부분은 식 (13)과 같이 분해가 가능해진다.

$$\ln f(x,y) = \ln i(x,y) + \ln r(x,y) \quad (13)$$

식 (13)을 푸리에 변환을 거쳐서 필터를 통과시키게 되며, 식 (14),(15)로 나타낸다.

$$\mathfrak{F}\{F(x,y)\} = \mathfrak{F}\{I(x,y)\} + \mathfrak{F}\{R(x,y)\} \quad (14)$$

$$H(u,v)F(u,v) = H(u,v)I(u,v) + H(u,v)R(u,v) \quad (15)$$

주파수 영역의 필터를 거친 후 푸리에 역변환을 이용하여 변환한다. 변환한 정보를 다시 지수함수를 이용하여 원래의 영역으로 복원한다. 수식은 아래의 식 (16),(17)로 나타낸다.

$$\mathfrak{F}^{-1}\{H(u,v)F(u,v)\} = \mathfrak{F}^{-1}\{H(u,v)I(u,v)\} + \mathfrak{F}^{-1}\{H(u,v)R(u,v)\} \quad (16)$$

$$\exp[F'(x,y)] = \exp[I'(x,y)] + \exp[R'(x,y)] \quad (17)$$

그림 5에서는 필터 처리 영상에 관한 예를 보이고 있다.



(a) 원본

(b) 필터 통과 후

그림 5. 호모 물픽 필터의 예

#### 조명 보정 필터(Illumination compensation filter)

얼굴에 비추어지는 조명의 위치가 다를 때 이미지는 그림자를 나타내거나, 한 부분만 밝아지는 편향조명의 형태를 나타낸다. 그러나 그림자 부분은 조명의 방향에 따라 그 위치가 변하므로 지역적으로 밝기 분포가 변하게 되고, 편향된 조명의 경우에는 그림자 영역보다는 넓은 영역에 대해서이긴 하지만 역시 밝기 분포가 지역적으로 변하게 된다. 따라서 같은 얼굴 내에서의 지역적인 밝기 분포를 일정하게 분포시키기 위해 얼굴의 배경 조명의 분포를 조사한다. 조사된 배경 조명의 분포는 조명 변화도(illumination gradient) 형태를 취하게 되고 이를 이용하여 조명의 영향을 보상할 수 있다[48].

조명 보정필터는 영상에 대해서 지역적 밝기를 이용한 고주파 필터를 적용한다. 지역적 밝기 차이란 일정한 크기의 윈도우 내에서 중앙점의 밝기와 윈도우

전체의 밝기 평균과의 차이를 의미한다. 이는 미디언 필터(median filter)를 거치기 전의 중앙값에서 거친 후의 중앙값을 뺀 값으로 구해질 수 있는데, 윈도우의 크기가  $(2n+1) \times (2n+1)$  일 때, 조명 보정을 위해 생성된  $I'(x, y)$ 의 값은 식 (18)로 구해지고, 그것을 이용하여 새로운 중앙점  $(x, y)$ 의 밝기  $G(x, y)$ 를 식 (19)와 같은 방법으로 구한다.

$$I'(x, y) = \frac{\sum_{i=-\infty}^{\infty} \sum_{j=-\infty}^{\infty} I(x+i, y+j)}{(2n+1)^2} \quad (18)$$

$$G(x, y) = \max(I(x, y) - I'(x, y), 0) \quad (19)$$

$I'(x, y)$  : 배경조명 모델링 함수  
 $I(x, y)$  : 원 영상  
 $G(x, y)$  : 개선 영상

윈도우의 크기가 입력 이미지의 크기에 비해 상대적으로 큰 값이라면 필터를 통한 출력의 분포는 입력 이미지를 전체적으로 밝게, 또는 어둡게 한 것과 같은 효과를 낸다. 윈도우의 크기가 입력 이미지에 비해 상대적으로 작은 값이라면 필터를 통한 출력은 윤곽선 근처의 밝기의 차이가 아주 심한 부분만 부각되어 많은 정보를 잃게 된다. 그러므로 조명의 영향을 줄이기 위한 적절한 이미지를 얻기 위해서는 입력 이미지의 크기를 고려하여 적절한 윈도우의 크기를 지정해야 한다. 실험에 사용한 입력 이미지의 크기는  $128 \times 128$ 로서 조명의 영향을 줄이면서 질감 정보를 충분히 유지할 수 있는 윈도우 크기의 실험치는  $19 \times 19$ 에서  $25 \times 25$  정도였다. 그림 6은 조명 보정 필터에 대한 예를 보인다.



그림 6. 조명 보정

### 히스토그램 평활화 필터(Histogram equalization filter)

빈약한 명암 값 분포를 가진 영상은 히스토그램 평활화 처리에 의해 향상될 수 있다. 히스토그램 평활화의 궁극적인 목적은 일정한 분포를 가진 히스토그램을 생성하는 것이다. 그 결과 어두운 영상은 밝아지고 너무 밝은 영상은 조금 어두워져 적당한 명도 값을 유지하게 된다. 이것은 정규화된 축적 히스토그램을 그레이 스케일 매핑함수로 이용하여 구현된다[27].



그림 7. 히스토그램 평활화

### 3. 4. 진화 알고리즘을 이용한 전처리 필터의 조합

일반적으로 널리 사용되는 진화 알고리즘은 유전자 알고리즘으로 1975년 Holland에 의해서 제안되었다[49]. 유전자 알고리즘은 적자생존이라는 다윈의 가설을 모방하여 유전형간의 경쟁을 통해 주어진 환경에 잘 적응하는 유전형을 찾아내며 이들을 교배와 변이를 통하여 여러 세대를 반복하는 과정에서 특정목적에 부합되는 형질로 개량해 가는 절차이다.

유전 알고리즘이 다른 탐색이나 최적화 방법과 다른 점은 다음과 같다.

단순 point 탐색이 아닌 multi point 탐색 방법이다.

탐색에 비용 정보(fitness function)를 이용하며, blind search를 한다.

결정론적인 규칙이 없고 확률적 연산자를 사용하여 수행된다.

위와 같은 특징으로 인해 다른 탐색 또는 최적화 방법에 비하여 전역적 해를 구할 가능성이 높으며 효율적이라고 알려져 있다[49, 50].

유전 알고리즘의 진행과정은 아래 그림 8과 같이 진행된다.

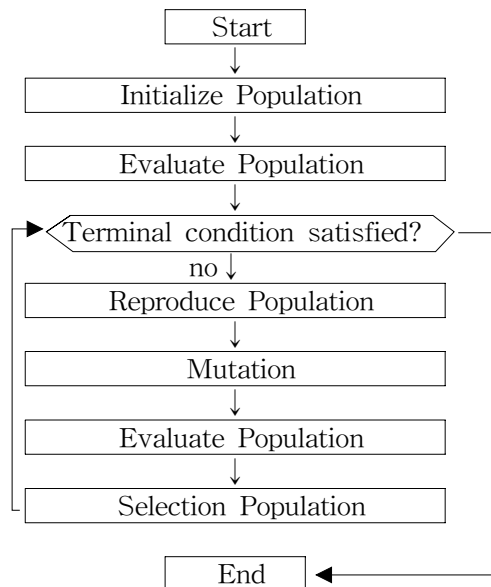


그림 8. 유전자 알고리즘의 진행과정

초기에는 유전체를 임의로 초기화시키고 각각의 적응도를 평가한다. 이를 토대로 우수한 유전자를 선택하고 선택된 구성원간의 교배(crossover)를 통해 새로운 유전형을 탄생시킨다. 여기에 비교적 낮은 확률의 돌연변이(mutation)를 추가하여 끊임없이 새로운 유전형을 발생시키고 적응도를 평가하는 작업을 반복한다. 이렇게 되면, 적응도가 우수한 유전형일수록 그 자손을 남길 수 있는 확률이 높아지므로 전체 유전집단의 평균 적응도는 대체로 향상되며 많은 수의 반복을 거치면 그 중에서 사용자가 원하는 수준을 만족시키는 유전형을 찾아낼 수 있게된다.

실험에서는 최적의 영상을 찾기 위한 필터 조합을 이 알고리즘을 이용하여 도출해 내었다.

## 4. 적응적 얼굴 인식 시스템의 구성

전체 시스템은 크게 진화신경망의 학습, 필터조합의 진화, 등록, 인식 의 네 단계를 거치게 되며, 진화신경망 학습과정은 4. 1절의 과정을, 필터조합 진화과정의 경우 4. 2절에서 영상 필터에 대해 정의된 과정을 사용한다.

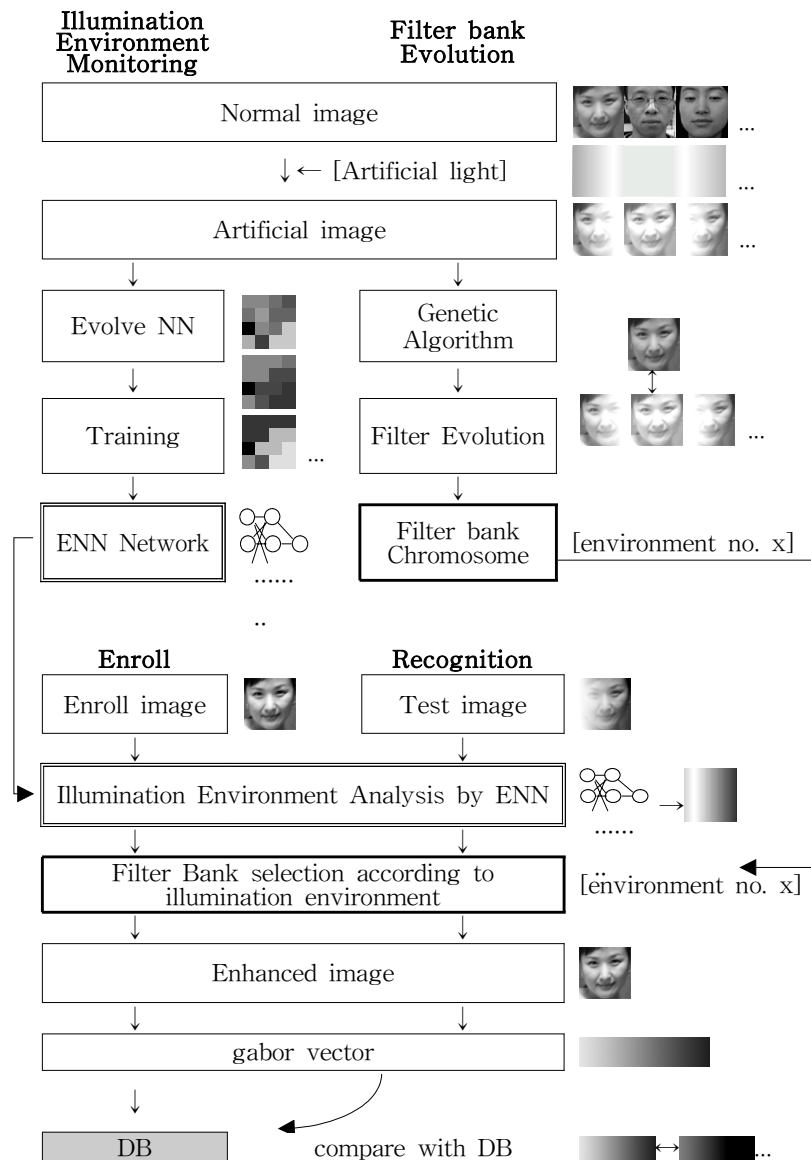



그림 9. 얼굴인식 시스템의 구성.



## 4. 1. 진화신경망의 학습

진화신경망의 가중치는 일반적인 역전파 신경망의 실수 가중치를 그대로 식 (10)과 (11)을 사용하여 표현하며, 연결구조는 앞서 설명된 노드의 Direct encoding을 위한 일반화 구조를 사용하게 된다. 실험적으로 구성된 일반화된 노드에 대해 진화가 종료된 후 신경망은 그림 10과 같이 변화하였다.



2-2-2 구조(연결수 8 → 6)

그림 10. 연결구조의 진화

신경망 진화를 위한 적합도 함수는 식 (20)과 같이 오류 역전파 신경망의 출력오류를 합산한 후 노드의 함수와 가중치에 대한 함수를 승산한다.

$$Fitness = \frac{1}{\sum_{i=1}^k f'(n_i(t))(o_i - n_i(t))} * f(n) \cdot f(w) \quad (20)$$

$$f(n) = \frac{a}{n_{\max} - n_{\min}} (n - n_{\min}) \quad (0 < a \leq 1) \quad (21)$$

$$f(w) = \frac{b}{w_{\max} - w_{\min}} (w - w_{\min}) \quad (0 < b \leq 1) \quad (22)$$

위의 식에서  $a$  와  $b$  는 임의로 주어지게 되며, 실험에서는 0.5로 정의하였다. 식에 의해 신경망을 진화시킬 경우 연결강도에 대해 전역해를 구할 수 있고, 입력 연결강도의 총합이 기준치 미만인 뉴런은 삭제가 되어 성능을 유지하면서 최소의 노드수를 가질 수 있게 된다.

만들어진 진화신경망의 학습은, 자체적으로 보유한 얼굴 이미지들에 대해 인공적인 조명을 추가시킨 후, 이들에 대해 4 x 4 모자이크 영상을 만들어 입력으로 사용하였다. Belhumeur와 Kriegman 의 연구[26]에서는 3개의 이미지를 이용한 보다 많은 가상 조명 상태를 만드는 방법을 제안했으나, 실험에 사용될 이미지들의 조명 상태의 종류가 그다지 많지 않기 때문에 9종류로 제한하였다. 만일 단순한 계산만으로 모든 조명 상태를 구별한다면 수십 가지의 조명 방향이 정의될 경우 인식에 무리가 따르지만, 진화 신경망을 사용할 경우 이를 충분히 구별해 낼 수 있다.



그림 11. 조명 환경의 정의

정의에서, Original 이미지는 자체적으로 보유한 조명상태가 동일한 얼굴 데이터들에 대해 전체 평균을 취한 값을 기준으로, 나머지 8종류의 가상 영상은 그림 12와 같이 각각 3. 1절에서 설명된 조명 환경 모델링을 사용하였으며, 밝은 쪽은 50의 가산 잡영 및 20의 승산 잡영, 어두운 쪽은 -50의 가산 잡영 및 -20의 승산 잡영, 편향 조명은 가중치 함수에 의해 생성하였다.




그림 12. 가상 영상의 생성

실험에 사용된 진화신경망은 최초 입력노드 16개, 은닉노드 16개, 출력노드 4개로 시작하여 진화하도록 하였고, 출력노드의 값은 0~1 사이로 정의하여 각 노드의 출력 값 0.5를 기준으로 총 16종류의 조명 환경을 판별할 수 있도록 하였다. 단, 실험에서 정의한 조명 환경은 9종류이므로 나머지 7개의 출력 값에 대해서는 기각으로 판별하였다.

## 4. 2. 영상처리 필터 조합

영상의 질 향상을 위해서 사용하는 기본적인 방법은 필터를 거치는 것이다. 3. 1절에서 설명되었던 조명 잡영들을 제거하기 위한 기본적인 접근은 다음과 같다. 인식기가 적응을 하기 위한 환경은 입력되어지는 이미지들에 대한 정의된 인공적인 조명 잡영을 추가한 것이고, 그것들에 적응하는 것이 실세계의 환경들에 대해 적응하는 것으로 가정을 한다. 인공적인 잡영은 밝기, 조명 방향 등의 환경 요소들을 포함하고 있고, 그러한 환경 요소들이 제거된 정규화된 이미지를 만들기 위해서 그 외 요소들을 분리시키는 작업을 수행해야 한다. 즉, 입력 이미지  $I(x, y)$ 는 인식을 위한 최적 이미지인 정규 이미지  $O(x, y)$ 와 그 외의 부분들인 잡영들의 합  $N(x, y)$ 의 합으로 나타낼 수 있고, 식으로 나타내면

$$I(x, y) = N(x, y) \cdot O(x, y) \quad (23)$$

이 된다.  $N(x, y)$ 는  $m$ 개의 개별적인 잡영들의 선형 결합을 나타내며,

$$N(x, y) = \begin{bmatrix} n_1(x, y) \\ n_2(x, y) \\ \vdots \\ n_m(x, y) \end{bmatrix} = \begin{bmatrix} n_{11}(x, y) & n_{12}(x, y) & \cdots & n_{1d}(x, y) \\ n_{21}(x, y) & n_{22}(x, y) & \cdots & n_{2d}(x, y) \\ & & \ddots & \\ n_{m1}(x, y) & n_{m2}(x, y) & \cdots & n_{md}(x, y) \end{bmatrix} \quad (24)$$

식 (24)와 같은  $m$ 행  $d$ 열 행렬로 표시할 수 있다( $m$ =잡영 개수,  $d$ =이미지 차원).  $n_i(x, y)$ 는  $i$ 번째의 개별적 잡영을 나타내는 벡터이다. 이미지  $I(x, y)$ 에서 전체 잡영  $N(x, y)$ 를 제거하기 위해서는 개별적 노이즈들을 제거 할 수 있는 필터  $f_j$  들의 최적 조합으로 정의되어진  $F$ 를 이용한다.  $F$ 는 다음의 식을 성립하도록 만들어진 행렬이며, 3. 4절에서 설명한 유전자 알고리즘을 이용하여 만들어진다.

$$O(x, y) = F(x, y) \cdot N(x, y) \cdot O(x, y) \quad (25)$$

즉, 식 (23)과 (24)에 의해 유도된 식 (25)는 입력 이미지  $I(x, y)$ 가 최적의 필터의 조합을 나타내는  $F(x, y)$ 를 거치게 되고, 인식을 위한

$$O(x, y) = F(x, y) \cdot I(x, y) \quad (26)$$

정규 이미지  $O(x, y)$ 를 구할 수 있음을 보인다.

진화 알고리즘에서 필터 조합을 위한 적합도 산출은 각각의 정의된 조명 환경에서 식 (27)과 같이 나타내어진다.

$$Fitness = 1 - \sum_{i=1}^k \left( \frac{\sum_{j=1}^m \sqrt{(T_i - OrgT_j)^2}}{m} - \frac{\sum_{j=1}^{k-m} \sqrt{(T_i - NotT_j)^2}}{k-m} \right) \quad (27)$$

T	:	등록된 영상에 대해 필터를 통과한 결과
OrgT	:	등록된 영상들 중 T와 등록ID가 같은 영상
NotT	:	등록된 영상들 중 T와 등록ID가 다른 영상
k	:	전체 등록된 영상의 수
m	:	한사람 당 등록되는 영상의 수

필터 Chromosome 은 미리 정의된 환경 당 하나씩 존재하며, 형식은 표 1과 같다.

표 1. 필터 Chromosome 의 구성

1	Homomorphic 필터 사용 여부
2	Illumination 필터 사용여부
3	Histogram 필터 사용여부
4~10	Homomorphic 필터 파라미터.

1	2	3	4	5	6	7	8	9	10
use/not use			homomorphic						

정의된 환경의 수는 4. 1절에서와 같이 9개로 정의하고 자체적으로 보유한 조명상태가 동일한 얼굴 데이터에 대해 인공적으로 정의된 조명을 추가한 후 각각의 필터 조합을 도출하였다.

### 4. 3. 가보 변환

시스템의 인식 부분에서는 영상의 특징 추출 방법으로 가보 변환을 사용한다. 가보(Gabor)함수를 이용하여 전처리 된 영상을 얼굴의 특징 벡터로 사용하는 이유는 그의 생물학적인 연관성 및 물리적인 특성 때문이다. 가보는 인간의 기본적인 시각 피질 내에 있는 일반적인 세포의 수용계와 비슷한 모형을 하고 있다[51]. 가보 함수는 공간 영역 및 주파수 영역에서 지역적으로 분포되어 있고, 평면파가 가우시안 함수에 의해서 제한된 모형을 하고 있다.

인간의 기본적인 시각 피질내의 일반적인 세포는 대응되는 수용계(Receptive fields)를 가지고 있다. Hubel과 Wiesel은 오래 전의 연구 조사에서 이들 세포들을 에지 검출기를 묘사하였다. 여기에 대한 많은 연구 조사들 중에 Jones와 Palmer에 의한 1987년도의 연구조사에서 이들은 고양이의 일반적인 세포들이 주파수의 특정 영역에 대응한다는 사실을 입증했다[52].

또한 Pollen과 Ronner은 고양이의 피질의 인접한 세포들간의 위상 관계를 조사하였다. 그들은 비슷한 주파수 특성을 가지고 인접한 쌍의 세포들간의 기함수적인 대칭성 및 우함수적인 대칭성을 발견하였다. 이런 결과들을 토대로 가보 함수는 사이(sine)항과 코사인(cosine)항을 가지고 있는 복소함수로 나타내어질 수 있는 것이다[8].

Jones와 Palmer는 수용계를 가우시안에 의해 둘러싸인 평면파인 2차원 가보 함수들로 표현할 것을 제안하였고 Pollen과 Ronner의 연구의 결과에 의하면 일반적인 세포들은 하나의 세포가 각각 2차원 평면상의 x축 및 y축에 대해서 각각 대칭인 쌍으로서 표현될 수 있다고 하였다. 위의 두 가지 결과를 종합하여 볼 때 가보 함수는 다음과 같이 제한된 평면파와 같이 사인항과 코사인항을 가지고 있는 지수함수로서 나타낼 수 있을 것이다. 이것은 가보 커널의 식 (28)로 나타낸다.

$\vec{k}$ 는 중심주파수를 나타내는데, 식에서 보듯이  $\vec{k}$ 는 고정된  $\sigma$ 의 값에 따라 가우시안의 폭을 제한해 준다는 사실을 알 수 있고, 주파수 영역에서 크기가 작은 중심주파수에서는 높은 해상도로 분석하며, 높은 중심주파수에서는 낮은 해상도로 분석한다는 것을 알 수 있다.

$$\phi_j(\vec{x}) = \frac{k_j^2}{\sigma^2} \exp\left(-\frac{k_j^2 x^2}{2\sigma^2}\right) [\exp(i\vec{k}_j \vec{x}) - \exp\left(-\frac{\sigma^2}{2}\right)] \quad (28)$$

$\exp\left(-\frac{k_j^2 x^2}{2\sigma^2}\right)$  : 평면 파의 모양을 제한하는 가우시안 외곽.

$\exp(i\vec{k}_j \vec{x})$  : 복소 평면파.

$\exp\left(-\frac{\sigma^2}{2}\right)$  : DC 성분을 억제하는 부분.

$\frac{k_j^2}{2\sigma^2}$  : 영상에서의 전력 스펙트럼이 주파수의 제곱에 반비례하는 성질에 대한 보상을 위한 부분[53].

가보 함수는 이미지의 다양한 조명에 대해서 안정성을 제공할 뿐만 아니라 이미지의 왜곡, 회전, 크기, 그리고 변형에 대해서도 안정적이라고 보고되었다 [14, 15, 54].

따라서 가보 변환을 이용한 이미지 영상에서의 가보 벡터 추출은 이미지 영상의 특징점  $\vec{x}$  를 중심으로 식 (28)의 가보 커널  $\psi_j(\vec{x})$ 을 식 (29)와 같은 방법으로 수행한다.

$$J_j(\vec{x}) = \int I(\vec{x}') \psi_j(\vec{x} - \vec{x}') d^2 \vec{x}' \quad (29)$$

$$\vec{k}_j = \begin{pmatrix} k_{jx} \\ k_{jy} \end{pmatrix} = \begin{pmatrix} k_v \cos \phi_\mu \\ k_v \sin \phi_\mu \end{pmatrix}, \quad k_v = 2^{-\frac{\nu+2}{2}} \pi, \quad \phi_\mu = \mu \frac{\pi}{8} \quad (30)$$

여기에서, 가보 커널  $\psi_j(\vec{x})$ 의  $\vec{k}$ 의 값은 특징점  $\vec{x}$ 에서의 주파수의 크기 5개  $\nu = 0, \dots, 4$  와 주파수의 방향 8개  $\mu = 0, \dots, 7$  에 관한 값이다. 식 (29)의  $J_j(\vec{x})$ 를 특징벡터 제트(jet)라 말하고, 계산되어진 제트는 이미지의 한 픽셀에 대해 주파수의 크기와 방향에 관련된 40개의 값들의 집합으로 나타내며, 식 (31)과 같이 크기(magnitude)  $a_j(\vec{x})$ 와 위상(phase)  $\phi_j(\vec{x})$ 로 구성 된다.

$$J_j = a_j \exp(i\phi_j) \quad (31)$$

인식에 있어서 안정적인 결과를 얻기 위해서는 크기(magnitude)인  $a_j(\vec{x})$  만을 가지고 유사도를 계산한다. 그러므로 하나의 특징점  $\vec{x}$ 에서의 특징 벡터는 다음과 같이 정의 할 수 있다.

$$F(\vec{x}) = (G_{0,0}(\vec{x})^t \ G_{0,1}(\vec{x})^t \ \cdots \ G_{4,7}(\vec{x})^t)^t \quad (32)$$

$F(\vec{x})$ 는 특징점  $\vec{x}$ 에서의 특징 벡터이며,  $G_{\mu,\nu}(\vec{x})$ 는  $\mu$  와  $\nu$  가 각각  $\mu = 0, \dots, 7, \nu = 0, \dots, 4$ , 일 때의  $J_j(\vec{x})$ 의 크기(magnitude)가  $a_j(\vec{x})$ 이다. 인식을 수행할 때 특징점의 개수는 여러개일 수 있다. 그러한 특징점들에 관한 특징 벡터는 하나의 특징 벡터 집합  $V$ 로 정의하며,

$$V = (F(\vec{x}_1) \ F(\vec{x}_2) \ \dots \ F(\vec{x}_n)) \quad (33)$$

와 같이  $n$ 개의 특징점에서 생성되는 특징 벡터 집합  $V$ 를 표현한다. 실험에서는 그림 13과 같이 눈 주위의 6개 점을 이용하여 특징 벡터를 추출하였다.




그림 13. 가보 벡터 추출

인식 실험에 사용한 특징점의 개수가 이미지 당 6개이기 때문에 특징 벡터 집합  $V$ 의 차원은 240이 되고, 이것을 이용하여 미리 등록된 벡터들과의 거리 값을 계산하여 가장 가까운 거리를 가지는 벡터에 대해 해당하는 사람을 인식하게 된다.



#### 4. 4. 얼굴 영상의 등록

등록단계에서는 등록할 이미지에 대해 진화신경망을 이용하여 이미지의 상태를 판별한 후 선택된 환경상태에 해당하는 필터조합을 통과하여 향상된 이미지를 생성한 후 이에 대한 가보변환을 수행하여 등록하게 된다. 이미지의 상태를 먼저 판별하고 필터를 적용하는 이유는, 등록되는 데이터들이 모두 정상조명이 라고 보장할 수가 없고, 이 과정에 의해 보다 높은 인식률을 얻을 수 있기 때문이다.

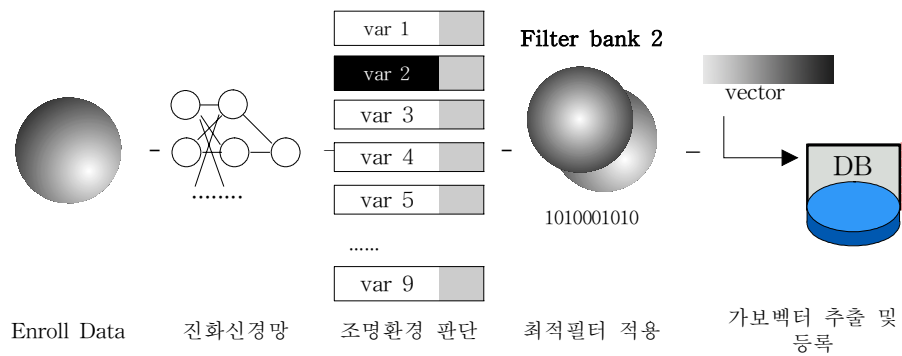


그림 14. 얼굴 등록 과정

## 4. 5. 얼굴 인식

인식 단계에서는 외부의 조명 환경을 판단하는 진화신경망을 이용하여 영상  
의 상태를 전달받아 이미 진화되어 있는 적합한 필터 Chromosome을 선택하게  
된다. 그후 해당하는 필터조합에 의해 생성된 이미지의 가보벡터를 추출한 후  
이미 등록된 DB의 가보벡터와 거리 값을 비교하여 가장 적은 값을 가지는 것  
을 선택한다.

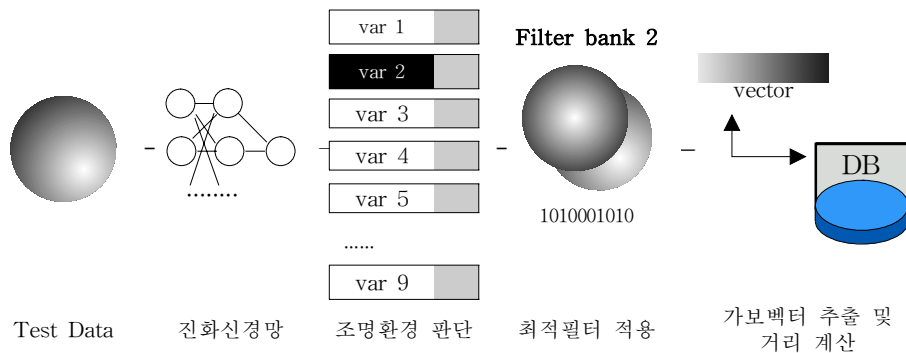


그림 15. 얼굴 인식 과정

실험에서는 단순히 9개의 환경만을 정의했으나, 이 수를 늘릴경우 보다 정확  
한 인식이 가능하다.

## 5. 실험결과

앞서 제안한 방법에 의해 각각의 환경에 대한 얼굴인식 실험을 수행하였다. 실험에 사용된 환경은 Pentium III 866MHz, Microsoft Windows 2000 환경에서 Visual C++ 6.0 컴파일러를 사용하였다. 실험으로 사용된 데이터는 자체적으로 보유한 동일 조명상태의 100명에 대한 정면 얼굴 데이터 1000개와, AR Face DB[55] 의 33명에 대한 얼굴이미지 총 429장중 선글라스 착용을 제외한 330장, Yale Face DB[56] 의 15명 얼굴 이미지 중 좌, 우측 편향조명과 역광을 받은 이미지를 포함한 조명데이터 각 4장씩 총 60장, 그리고 FERET[57]에서 제공하는 1209명에 대한 이미지 2418장이 사용되었다.

자체 보유 데이터는 각 사람마다 5장씩의 얼굴을 등록에 사용하였으며, AR Face DB 에 대해서는 정상조명의 얼굴 3장씩을, Yale Face DB에 대해서는 정상조명 얼굴 1장을, FERET DB 에 대해서는 gallery 이미지를 등록에 사용한 후 나머지 이미지들에 대해 테스트를 수행하였다. 단, 모든 데이터는 얼굴 부분에 대해서만 128x128 이미지로 재추출한 후 사용되었다.

실험을 위하여 설정한 다른 여러 가지 환경조건에 대한 제약은 표 2와 같다.

표 2. 실험 환경 제약 조건

환경요소	학습 데이터	테스트 데이터
얼굴 방향	정면	정면
표정	변화 가능	변화 가능
영역	얼굴 영역	얼굴 영역
안경	착용 가능	착용 가능
머플러	없음	착용 가능
머리모양	변화 가능	변화 가능
조명상태	정상 조명	조명 방향과 강약에 따라 9종류로 구별

실험들에 대한 성능의 평가는 다음과 같은 식에 의해 결정된다.

$$(\text{성공수}) = (\text{전체영상수}) - (\text{기각수}) - (\text{에러수}) \quad (34)$$

$$(\text{성공률}) = \frac{(\text{성공수})}{(\text{전체영상수})} \quad (35)$$

$$(\text{에러율}) = \frac{(\text{에러수})}{(\text{전체영상수})} \quad (36)$$

$$(\text{신뢰도}) = \frac{(\text{성공수})}{(\text{전체영상수}) - (\text{기각수})} \quad (37)$$

## 5. 1. 조명상태 판단에 대한 실험

진화신경망의 학습은 자체 보유 데이터 중, 등록에 사용되지 않은 영상 100장에 대해 9종류의 정의된 조명효과를 추가한 후 4x4의 모자이크 영상으로 바꾸어 진화신경망의 입력으로 사용하였다. 성능을 판단하기 위해 별도로 같은 데이터에 대해 역전파 신경망에 대해서도 학습을 하였으며, 단순계산에 의한 판단결과와 비교하였다. 또한 조명 환경의 판단에 대해 대상 데이터들이 실제로 어떤 영역에 속하는지는 표 3을 기준으로 하였다.

표 3. 조명 환경 기준

조명 환경	기준
밝은 조명 (B)	대상 데이터에 대해 전체 밝은 조명 영상의 평균값을 취한 후 학습 영상중 정상조명의 평균값보다 50 이상 클 때
정상 조명 (org)	대상 데이터에 대해 전체 정상조명 영상의 평균값을 취한 후 학습 영상의 평균값과 50 미만의 차이를 보일때
어두운 조명 (D)	대상 데이터에 대해 전체 어두운 조명 영상의 평균값을 취한 후 학습 영상중 정상조명의 평균값보다 50 이상 작을 때
편향조명 좌, 우측 (L, R)	대상 데이터의 전체 편향조명 영상의 좌, 우측 평균값을 취한 후 각각의 차이가 30이상일 때

단순계산의 판단법은 표 3을 기준으로, 4x4의 16개로 이루어진 모자이크 영상에 대해 평균이 100~ 150 사이의 값이면 중간 밝기의 영상, 100 이하이면 어두운 조명, 150 이상이면 밝은 조명으로 하였으며, 좌, 우측의 평균값을 취하여 두

평균값 차이가 30이 넘을 경우 편향조명으로 판단하였다.

표 4에서 나온 실험 결과는 테스트를 위한 이미지 500장에 대해 그림 11에서 정의된 8종류의 조명효과를 추가한 영상과 정상적인 영상에 대해 조명 환경 판단이 정확한지 비교한 것이다. 표에서 에러는 잘못된 조명상태로 판별한 경우이고, 기각은 정의된 조명 환경 중 어느 것도 선택되지 않은 경우이다. 단순 계산법의 결과는 무조건 정의된 환경에 속하게 되므로 기각이 없다.

표 4. 자체 보유데이터에 대한 조명상태 판단

단위 : /500

조명상태	org			B			D			L				
	성공	에러	기각	성공	에러	기각	성공	에러	기각	성공	에러	기각		
진화신경망	500	0	0	499	1	0	500	0	0	500	0	0		
역전파 신경망	478	17	5	488	4	8	476	18	6	479	12	9		
단순 계산법	499	1	-	499	1	-	500	0	-	497	3	-		
R			BL			BR			DL			DR		
성공	에러	기각	성공	에러	기각	성공	에러	기각	성공	에러	기각	성공	에러	기각
499	1	0	498	2	0	498	1	1	500	0	0	498	1	1
485	5	10	493	4	3	482	12	6	493	3	4	491	4	5
495	5	-	498	2	-	500	0	-	496	4	-	494	6	-

실험결과 그림 16에서 보이는 것처럼 역전파 신경망의 성능이 성공률 97%, 에러율 1.76% 로 99.5% 의 성공률과 0.49%의 에러율을 보이는 단순 계산법 보다 오히려 떨어지는 것을 알 수 있는데, 이것은 역전파 신경망의 학습이 지역 최소점에 빠지는 현상으로 설명할 수 있다. 진화신경망의 경우 전역해를 찾기 때문에 성공률 99.82%, 에러율 0.13% 로 가장 성능이 뛰어남을 볼 수 있다.




그림16. 자체 보유데이터에 대한 조명상태 판단

AR Face DB는 좌측 편향조명, 우측 편향조명, 밝은 조명 의 3가지 조명형태에 대해 선글라스를 낀 모습, 머플러를 착용한 모습, 정상적인 모습 3가지를 각각 제공한다. 데이터의 실제 조명 영역은 표 3을 기준으로 아무것도 착용하지 않은 얼굴들에 대해 전체 평균값을 취하여 판별한 결과 각각 BL(밝은 조명 좌측), BR(밝은 조명 우측), B(밝은 조명) 그룹에 속하는 것으로 나타났다.

선글라스 착용의 경우 눈 주위에서 특징을 추출하여야 하는 인식의 과정에 의해 인식성능의 비교가 어려우므로 제외하였으며, 어두운 조명과 보통 밝기의 좌, 우측 편향 조명은 제공하지 않으므로 별도로 인공조명을 추가하여 사용하였다. 또한 앞서 설명한 바와 같이 전체 영상을 사용하지 않고 얼굴 영역만 채추출하여 사용하였다.

표 5. AR Face DB 에 대한 조명상태 판단

단위 : /66

			[자연조명]											
조명상태			B			BL			BR					
			성공	에러	기각	성공	에러	기각	성공	에러	기각			
진화신경망			58	5	3	56	2	8	57	4	5			
역전파 신경망			56	0	10	48	2	16	43	7	16			
단순 계산법			44	22	-	42	24	-	41	25	-			
[인공조명]														
D			DL			DR			L			R		
성공	에러	기각	성공	에러	기각	성공	에러	기각	성공	에러	기각	성공	에러	기각
57	2	7	59	5	2	56	7	3	55	3	8	61	2	3
52	6	8	47	2	17	56	5	5	45	7	14	49	9	8
36	30	-	44	22	-	38	28	-	40	26	-	42	24	-

표 5에서 데이터들은 앞서 설명한 바와 같이 머플러를 착용한 것과 그렇지 않은 두 종류의 얼굴에 대한 것이다. 단, 정상조명에 대한 판단은 큰 의미가 없으므로 제외하였다. 결과에서 보이는 것처럼 앞서의 실험보다 전반적인 성능이 크게 떨어지고, 에러에 비해 기각이 많은 것을 알 수 있는데, 이것은 머플러의 영향으로 모자이크 영역이 실제 조명보다 어둡게 나타나기 때문이다. 이 경우 단순 계산법의 경우는 성공률 61.93% 에러율 38.07% 로 크게 성능이 떨어지는 반면에, 잡영을 흡수하는 특성이 있는 신경망 쪽의 경우 역전파 신경망은 성공

률 75%, 에러율 7.2%, 진화신경망은 성공률 86.93%, 에러율 5.68% 로 비교적 신경망쪽의 성능이 우수함을 보인다.




그림 17. AR Face DB 에 대한 조명상태 판단

Yale Face DB에서 제공하는 조명 데이터는 기본적인 정상 조명 외에 역광, 좌, 우측 편향 조명 3가지를 포함하여 1인당 4개의 이미지를 가진다. 이들 이미지에 대한 전체 평균 계산으로 본 글에서 정의한 조명 영역을 조사한 결과 정상조명은 그대로 org(정상조명) 그룹에, 나머지는 모두 D(어두운 조명), DL(어두운 조명 왼쪽), DR(어두운 조명 오른쪽)에 속하는 것으로 나타났다.

표 6. Yale Face DB 에 대한 조명상태 판단

단위 : /15

조명상태	org			D			DL			DR		
	성공	에러	기각	성공	에러	기각	성공	에러	기각	성공	에러	기각
진화신경망	13	1	1	13	2	0	14	0	1	14	1	0
역전파 신경망	11	4	0	12	2	1	13	1	1	13	2	0
단순 계산법	13	2	-	14	1	-	13	2	-	14	1	-

Yale Face DB에 대한 실험은 AR Face DB와 달리 인공 조명 없이 자연조명 상태 그대로만을 성능 측정에 사용하였다. AR Face DB에 비해 90% 정도로 보다 높은 성공률을 보이지만, 머플러 착용 등 다른 조건이 없고, 조명의 영향이 매우 확실하게 나타나기 때문이다. 또한 정확하게 모든 영상이 한 그룹에 속하지 않기 때문에 몇 개의 에러가 나타난다.




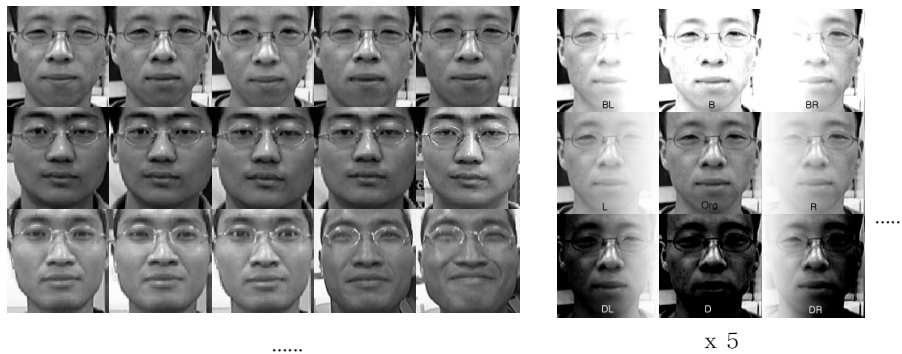
그림 18. Yale Face DB 에 대한 조명상태 판단

FERET DB의 경우는 별도로 편향 조명이나 밝고 어두운 정도를 따로 정의한 영상이 없다. 따라서 이 데이터들은 조명판단 실험에서 제외하고, 인식을 테스트에서만 사용하였다.



## 5. 2. 인식률에 대한 실험

얼굴인식 실험은 크게 두 가지로 이루어졌으며, 첫 번째는 미리 등록된 데이터에 대해 본 논문에서 설명된 최적조합 필터를 찾아 사용하는 방법과 일반적인 영상 필터링을 곧바로 적용한 방법을 사용한 방법을 비교하였다. 단순한 필터링의 경우 앞부분에서 판단된 조명상태에 따라 어둡거나 밝은 조명일 경우 호모몰픽 필터를 추가 적용하고, 편향조명의 경우에는 조명 보정 알고리즘을 추가 적용하였다. 히스토그램 평활화의 경우는 모든 경우에 항상 사용하도록 하였다. 단 실험에 사용된 모든 데이터는 두 눈을 기준으로 얼굴영역만을 추출한 것이다.



(a) 등록용 (b) 테스트용  
그림 19. 인식 테스트용 자체 보유 데이터



(a) 등록용 (b) 테스트용  
그림 20. 인식 테스트용 AR Face DB




그림 21. 인식 테스트용 Yale Face DB



(a) 등록용



(b) 테스트용

그림 22. 인식 테스트용 FERET DB

실험에 사용된 등록과 테스트용 이미지는 표 7을 기준으로 한다.

표 7. 등록 및 테스트 데이터

데이터 종류	등록용		테스트용	
	인원수	영상수	인원수	영상수
자체보유 데이터	100	500	100	4500
AR Face DB	33	99	33	198
Yale Face DB	15	15	15	45
FERET DB	1209	1209	1209	1209

자체보유 데이터는 총 100명에 대한 1000개의 영상중 1명당 각 5장씩을 등록

에 사용하고 나머지 500장에서 8종류의 인공조명을 추가한 4500개의 영상을 테스트로 사용하였다. AR Face DB의 경우는 33명에 대한 429개의 영상중 선글라스를 착용한 것과 등록에 사용된 1인당 3장의 영상을 제외한 조명 영향이 포함된 198개의 영상을, Yale Face DB는 15명에 대한 조명 판단 실험에 사용된 60개의 영상중 정상 조명을 가진 1인당 등록용 1장을 제외한 나머지 1인당 3장의 영상을 테스트에, FERET DB는 1209명의 gallery 영상을 등록으로, 1209개의 probe\_fafb\_expression 영상을 테스트용으로 사용하였다.

진화신경망에 대한 실험 결과는 다음과 같다.

**표 8. 진화 신경망에 의한 조명 판단 + 진화알고리즘 영상 필터링**

데이터 종류	영상수	사람수	성공	기각	에러	에러율	성공률	신뢰도
자체 보유 데이터	4500	100	4409	2	89	1.97 %	97.98 %	98.02 %
AR Face DB	198	33	192	0	6	0.3 %	96.97 %	96.97 %
Yale Face DB	45	15	43	0	2	4.44 %	95.56 %	95.56 %
FERET DB	1209	1209	1176	12	21	1.74 %	97.27 %	98.25 %

**표 9. 진화 신경망에 의한 조명 판단 + 일반적인 영상 필터링**

데이터 종류	영상수	사람수	성공	기각	에러	에러율	성공률	신뢰도
자체 보유 데이터	4500	100	4328	5	167	3.71 %	96.18 %	96.28 %
AR Face DB	198	33	189	0	9	4.54 %	95.45 %	95.45 %
Yale Face DB	45	15	40	0	5	11.11 %	88.89 %	88.89 %
FERET DB	1209	1209	1104	4	101	8.35 %	91.32 %	91.62 %

실험에서, 제안된 방법에 대한 결과가 전체적으로 97.2% 로 비교적 안정적인 인식 성능을 보인다. 반면에, 일반적인 영상필터링을 사용한 경우 93.06% 로 상대적으로 성능이 떨어진다는 것을 알 수 있다.

특이한 점으로 AR Face DB에서의 인식률이 조명 판단 실험에서 저조한 성능을 보인것과 관계없이 높는데, 이것은 가보백터화가 눈 주위에서 이루어지므로 머플러로 입을 가린 이미지에서는 큰 영향이 없기 때문이다.

역전과 신경망과 단순 계산법에 의해 조명 환경을 판단한 후 인식한 결과는 다음과 같다.

표 10. 역전과 신경망에 의한 조명 판단 + 진화알고리즘 영상 필터링

데이터 종류	영상수	사람수	성공	기각	에러	에러율	성공률	신뢰도
자체 보유 데이터	4500	100	4319	42	139	3.08 %	95.98 %	96.88 %
AR Face DB	198	33	182	2	14	7.07 %	91.92 %	92.86 %
Yale Face DB	45	15	41	1	3	6.67 %	91.11 %	93.18 %
FERET DB	1209	1209	1098	26	85	7.03 %	90.82 %	92.81 %

표 11. 역전과 신경망에 의한 조명 판단 + 일반적인 영상 필터링

데이터 종류	영상수	사람수	성공	기각	에러	에러율	성공률	신뢰도
자체 보유 데이터	4500	100	4302	85	113	2.51 %	95.6 %	97.44 %
AR Face DB	198	33	180	8	10	5.05 %	90.91 %	94.74 %
Yale Face DB	45	15	37	1	7	15.56 %	82.22 %	84.09 %
FERET DB	1209	1209	1048	30	131	10.83 %	86.68 %	88.89 %

표 12. 단순 계산법에 의한 조명 판단 + 진화알고리즘 영상 필터링

데이터 종류	영상수	사람수	성공	기각	에러	에러율	성공률	신뢰도
자체 보유 데이터	4500	100	4395	28	77	1.71 %	97.67 %	98.28 %
AR Face DB	198	33	175	7	16	8.08 %	88.38 %	91.62 %
Yale Face DB	45	15	43	0	2	4.44 %	95.56 %	95.56 %
FERET DB	1209	1209	1102	15	92	7.61 %	91.15 %	92.29 %

표 13. 단순 계산법에 의한 조명 판단 + 일반적인 영상 필터링

데이터 종류	영상수	사람수	성공	기각	에러	에러율	성공률	신뢰도
자체 보유 데이터	4500	100	4374	66	60	1.33 %	97.2 %	98.65 %
AR Face DB	198	33	171	12	15	7.58 %	86.36 %	91.94 %
Yale Face DB	45	15	39	3	3	6.67 %	86.67 %	92.86 %
FERET DB	1209	1209	1094	48	67	5.54 %	90.49 %	94.23 %

단순계산법과 역전과 신경망을 사용하여 조명 환경을 판단한 방법에서도 진화적응으로 영상 필터를 선택한 방법이 높은 성능을 보인다. 이것은 진화알고리즘의 경우 영상에 대해 필터의 사용유무와 파라미터를 위한 적절한 값을 찾아낼 수 있으나 일반적인 필터링은 획일적인 값만을 사용하기 때문에 본래의 영상의 질을 오히려 떨어뜨리는 결과가 나올 수도 있기 때문이다.

## 6. 결론 및 향후 연구방향

본 논문에서는 진화신경망을 이용한 조명 환경 판단과 진화 알고리즘을 사용한 적절한 영상 처리 및 가보변환을 사용하여 얼굴을 인식하는 방법을 제안하였다. 실험결과 얼굴영역의 조명이 비교적 심하게 변화함에도 불구하고 일반적인 방법에 비해 보다 안정적인 성능을 나타내었다. 실험에 사용된 4종류의 DB는 각각 자체적으로 보유한 정상 조명의 얼굴 데이터에 대해 가상 조명을 적용한 것과, 편향 조명 및 머플러 착용 영상이 포함된 AR Face DB, Yale Face DB, 그리고 FERET DB이다.

실험에서 일반적인 신경망이나 단순한 픽셀 평균 계산방법보다 진화신경망 쪽이 환경변수를 보다 잘 판단하는 것을 보였다. 또한 진화 알고리즘을 사용한 최적의 영상 필터 조합으로 조명 변화가 심각한 환경에서 해당하는 환경을 적절히 판단하고 그에 따른 최적의 필터 조합을 선택하는 방법을 이용하여 환경이 변화함에 따라 적절한 대응을 하도록 하였다.

향후 연구 방향으로 생각할 수 있는 것들은 다음과 같다. 하드웨어로 구성하기 위해 변화하는 주위환경을 보다 빠르고 적절하게 인식하는 센서에 대한 연구와, 더 세분화된 환경조건을 판단할 수 있는 영상분석 및 영상들을 적절히 정상적으로 변화시킬 수 있는 영상 필터에 대한 연구가 지속적으로 이루어져야 한다. 또한 유비쿼터스 컴퓨팅 환경과의 접목을 위해 실시간으로 얼굴인식을 수행할 수 있는 구성에 대한 연구가 필요하다.

## 참 고 문 헌

- [1] M.Weiser. The Computer for the 21st Century. Scientific American, September 1991. Reprinted in IEEE Pervasive Computing, 1(1), p. 18-25, 2002
- [2] IBM Pervasive Computing, <http://www.ibm.com>
- [3] MIT Oxygen Project, <http://oxygen.lcs.mit.edu/>.
- [4] University of Washington : Portolano - An expedition into invisible computing, <http://portolano.cs.washington.edu/>.
- [5] "Ubiquitous Sensing for Smart and Aware Environments", Irfan Essa, IEEE Personal Communications, pp. 47-9, October 2000.
- [6] Leandro Soares Indrusiak, et al. "Ubiquitous Access to Reconfigurable Hardware: Application Scenarios and Implementation Issues", Proceedings of the Design, Automation and Test in Europe Conference and Exhibition, 2003.
- [7] Stephen S. Yau, Yu Wang, and Fariaz Karim, "Development of Situation-Aware Application Software for Ubiquitous Computing Environments", Proceedings of the 26th Annual International Computer Software and Application Conference(COMPSAC'02), 2002.
- [8] Daniel A. Pollen and Steven F. Ronner, "Phase relationship between adjacent simple cells in the visual cortex," Science, 212:1409-1411, June 1981.
- [9] J. Daugman, "Face and gesture recognition: overview", IEEE Trans, PAMI, Vol. 19, No. 7, pp675-676, 1997

- [10] L. Sirovich and M. Kirby, "Low-dimensional procedure for the characterization of human faces", J. of Opt. Soc. Amer. A. Vol. 4, No. 3, pp519-524, 1987
- [11] M. Kirby and L. Sirovich, "Application of Karhunen-Loeve procedure for characterization of human faces", IEEE Trans. PAMI, Vol. 12, pp130-108, 1990
- [12] M. Turk and A. Pentland, "Eigenface for recognition", Journal of Cognitive Neuroscience, Vol. 3, No. 1, pp71-86, 1991
- [13] A. O'Toole, H Abdi, K. Deffenbacher and D Valentin, "Low-dimensional representation of face in higher dimensions of the face space", J. Opt. Soc. Am. A. Vol. 10, No. 3, pp 405-411, 1993.
- [14] L. Wiskott, J.M. Fellous, N. Kruger and C. v.d.Malsburg, "Face recognition by elastic graph matching", IEEE Trans. PAMI. Vol. 19, No. 7, pp775-779. 1997
- [15] Laurenz Wiskott, Jean-Marc Fellous, Norbert Kruger, and Christoph von der Malsburg, "Face Recognition by Elastic Bunch Graph Matching", Intelligent Biometric Techniques in Fingerprint and Face Recognition, eds. L.C. Jain et al., publ. CRC Press, Chapter 11, pp. 355-396, 1999.
- [16] N. Kruger, M. Potzsch, and C. v.d.Malsburg, "Determination of Face Positions and Pose with a Learned Representation Based on Labeled Graphs", Image and Vision Computing, pp655-673 August 1997.
- [17] Penio S. Penev and Joseph J. Atick, "A General Statistical Theory for Object Representation", Network: Computation In Neural Systems, Vol. 7, pp477-500, 1996.
- [18] Visionic Ltd., <http://www.faceit.com>, 1997.

- [19] Pentland A., Moghaddam B., Starner T., "View-Based and Modular Eigenspaces for Face Recognition", IEEE Conf. on Computer Vision & Pattern Recognition, Seattle, WA, July 1994.
- [20] Shang-Hung Lin, "An Introduction to Face Recognition Technology", Informing Science Special Issue on Multimedia Informing Technologies part 2, Vol. 3, No. 1, 2000.
- [21] Haddadnia, J., Faez, K., Moallem, P., "Neural network based face recognition with moment invariants," Image Processing, International Conference on, Vol. 1, pp. 1018 – 1021, 2001.
- [22] Ashit Talukder, "Adaptive Activation Function Neural Net for Face Recognition", California David Casasent Carnegie Mellon University, Department of Electrical and Computer Engineering Pittsburgh, PA 15213, 2001.
- [23] Lawrence, C. L. Giles, and A. C. Tsoi, "What size neural network gives optimal generalization? Convergence properties of backpropagation, " Univ. Maryland Tech. Rep. CS-TR-3617, 1996.
- [24] Y. Adini. Y. Moses, and S. Ullman, "Face recognition: The problem of compensating for changes in illumination direction," IEEE Trans. Pattern Anal. & Mach. Intell., vol.19, no.7, pp.721–732, July 1997.
- [25] A.S. Georgiades, D.J. Kriegman, and P.N. Belhumeur, "Illumination cones for recognition under variable lighting: Faces," Proc. IEEE Conf. on CVPR, pp.52–58,
- [26] P.N. Belhumeur and D. J. Kriegman. "What is the set of images of an object under all possible lighting conditions. In Proc. IEEE Conf. on Comp. Vision and Patt. Recog., pages 270–277, 1996
- [27] Rafael C. Gonzalez, Richard E. Woods, "Digital Image Processing" ,



Addison Wesley, p161~218, 1993.

- [28] J.Hertz, A.Krogh, and R. Palmer, "Introduction to the Theory of Neural Computation", Reading, MA: Addison=Wesley, 1991.
- [29] Joey Rogers, "Object-Oriented Neural Networks in C++", Academic Press, 1997
- [30] D. Rumelhart and J. McClelland, Parallel Distributed Processing, Vol.1. Cambridge, Mass. : MIT Press, 1986.
- [31] Miller. G.F., P.M. Todd, and S.U. Hedge, "Designing Neural Networks Using Genetic Algorithms." Proceedings of the 3rd International Conference on Genetic Algorithms, Morgan Kaufmann, San Mateo, CA. 1989.
- [32] Whitley. D., Starkweather and C. Bogart, "Genetic Algorithms and Neural Networks: Optimizing Connections and Connectivity", Parallel Computing Vol. 14, pp.347-361. 1990.
- [33] Harp. S.A., T. Samad, and A. Guha, "Towards the Genetic Synthesis of Neural Networks." in Proceedings of the Third International Conference on Genetic Algorithms. pp. 360-369. 1989.
- [34] Dodd. N., "Optimization of Network Structure Using Genetic Techniques", Proc. of the Intern. Conf on Neural Networks, Paris, 1990.
- [35] Kitano. H., "Empirical Studies on the Speed of Convergence of Neural Network Training using Genetic Algorithms." in Eighth National Conference on Artificial Intelligence, Vol II, AAAI, MIT Press. pp798-795. 1990.
- [36] X. Yao, "Evolving artificial neural networks", Proceedings of the IEEE, Vol. 87, No. 9, pp. 1423-1447, 1999.

- [37] P. J. B. Hancock, "GANNET: design of a neural net for face recognition by genetic algorithm," Tech. Rep. CCCN-6, Center for Cognitive and Computational Neuroscience, Dept. of Computing Sci. and Psychology, Stirling University, Stirling FK9 4LA, UK, August 1990.
- [38] Kasabov, N., "ECOS: A framework for evolving connectionist systems and the ECO learning paradigm", Proc. of ICONIP'98, Kitakyushu, Japan, Oct. 1998, IOS Press, 1222-1235
- [39] Kasabov, N., "Evolving Fuzzy Neural Networks - Algorithms, Applications and Biological Motivation", in: Yamakawa and Matsumoto (eds), Methodologies for the Conception, design and Application of Soft Computing, World Scientific, 1998, 271-274
- [40] D. Montana and L. Davis, "Training feedforward neural networks using genetic algorithms", in Proc. of Eleventh Int'l Joint Conf. on Artificial Intelligence, pp.762-767, Morgan Kaufmann, San Mateo, CA, 1989.
- [41] D.B.Fogel, L.J.Fogel, and V.W.Porto, "Evolving neural networks", Biological Cybernetics, vol.63, pp487-493, 1990.
- [42] M.Srinivas and L.M.Patnaik, "Learning neural network weights using genetic algorithms improving performance by search-space reduction", in Proc. of 1991 IEEE International Joint Conf. on Neural Networks(IJCNN'91 Singapore), vol.3, pp2331-2336, IEEE Press, New York, NY, 1991.
- [43] Y. Ichikawa and T.Sawa, "Neural network application for direct feedback controllers", IEEE Transactions on Neural Networks, vol. 3, pp224-231, March 1992.
- [44] R. D. Beer and J.C. Gallagher, "Evolving dynamical neural networks for adaptive behavior", Adaptive Behavior, vol. 1, pp91-122, 1992.

- [45] N. Kasabov, "Evolving Fuzzy Neural Network for Supervised/Unsupervised On-line, Knowledge-based Learning," IEEE Trans. on Man, Machine and Cybernetics, (in press), 2001.
- [46] F. Menczer and D. Parisi, "Evidence of hyperplanes in the genetic learning of neural networks", Biological Cybernetics, vol. 66, pp.283-289, 1992.
- [47] J. Antonisse, "A new interpretation of schema notation that overturns the binary encoding constraint", in Proc. of the Third Int'l Conf. on Genetic Algorithms and Their Applications(J. D. Schaffer, ed.), pp.86-91, Morgan Kaufmann, San Mateo, CA, 1989.
- [48] Ramesh Jain, Rangachar Kasturi, Brian G. Schunck, "Machine Vision," pp. 118-121, McGraw-Hill, 1995.
- [49] J.H.Holland, "Adaptation in Natural and Artificial Systems.", Ann Arbor, MI: The University of Michigan Press, 1975.
- [50] D.E.Goldberg, "Genetic Algorithms in Search, Optimization, and Machine Learning." Reading, MA:Addison-Wesley, 1989.
- [51] W. M. Theimer and H. A. Mallot, "Phase-based binocular vergence control and depth reconstruction using active vision," CVGIP: Image Understanding, 60(3):343-358, November 1994.
- [52] J. P. Jones and L. A. Palmer, "An evaluation of the two-dimensional gabor filter model of simple receptive fields in cat striate cortex," J. Neurophysiol., 58(6):1233-1258, 1987.
- [53] David J. Field, "Relations between the statistics of natural images and the response properties of cortical cells," Optical Society of America A, 4(12):2379-2394, 1987.

- [54] M. Potzsch, N. Kruger, C. Von der Malsburg, "Improving object recognition by transforming Gabor filter responses," *Network: Computation in Neural Systems*, 7(2):341-347, 1996.
- [55] Aleix Martinez and Robert Benavente in the Computer Vision Center (CVC) at the U.A.B, "The AR Face Database", [http://rv11.ecn.purdue.edu/~aleix/aleix\\_face\\_DB.html](http://rv11.ecn.purdue.edu/~aleix/aleix_face_DB.html)
- [56] P. N. Belhumeur, J. P. Hespanha, and D. J. Kriegman. "Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection". *IEE Transactions on Pattern Analysis and Machine Intelligence*, 19(7):711-720, 1997.
- [57] Vision Group of Essex University Face Database, "Description of Libor Spacek's Collection of Facial Images", <http://cswww.essex.ac.uk/allfaces>